

1 Descripción y Exploración de Datos

Este capítulo caracteriza el conjunto de datos empleado en el SAT, documenta las decisiones de preprocesamiento adoptadas y presenta los hallazgos del análisis exploratorio que fundamentan el diseño del sistema de modelado. La presentación se organiza en seis bloques: (i) fuente y composición del dataset; (ii) definición y justificación de los subconjuntos de trabajo; (iii) calidad y estructura de los datos; (iv) análisis estadístico de las notas académicas; (v) análisis de la actividad en plataforma; y (vi) análisis de correlaciones y síntesis de decisiones de diseño.

1.1 Fuente y Composición del Conjunto de Datos

Los datos provienen del curso IIND-2104 *Modelos Probabilísticos* de la Universidad de los Andes, dictado entre los semestres 202320 y 202520 —cinco cohortes consecutivas cubiertas entre 2023 y 2025. La información se integra a partir de dos fuentes complementarias:

- **Sistema de gestión académica institucional:** calificaciones oficiales de los tres parciales y de las evaluaciones continuas (actividades modulares, quizzes, talleres y proyectos, según el formato de cada semestre).
- **Plataforma Bloque Neón:** sistema de gestión del aprendizaje (LMS) que registra, por sesión y por módulo de contenido, el tiempo de estudio, los temas consultados, los módulos visitados y la frecuencia de acceso de cada estudiante.

El dataset crudo consolidado cuenta con **764 registros y 77 variables**, con cuatro posibles resultados académicos finales: **APROBÓ** (413 estudiantes, 54,1 %), **REPROBÓ** (141, 18,5 %), **RETIRADO** (164, 21,5 %) y **SIN NOTA** (46, 6,0 %).

La Figura 1 ilustra cómo se distribuyen estos resultados por semestre en términos absolutos y porcentuales, y la Tabla 1 detalla las frecuencias exactas.

Dos fenómenos merecen atención especial. Primero, la tasa de reprobación en 202510 (33,6 %) es la más alta del período y más del doble de la de 202410 (9,3 %), lo que sugiere variabilidad intercohorte que el modelo debe generalizar. Segundo, el semestre 202520 registra la mayor tasa de retiro (32,9 %), fenómeno atípico que podría obedecer a cambios en la política institucional de permanencia o a condiciones externas no capturadas en los datos.

1.1.1 Dos eras pedagógicas

Un rasgo estructural del dataset es la coexistencia de dos **formatos de evaluación continua**:




Figure 1: Composición del dataset por semestre y resultado académico. **Izquierda:** distribución absoluta. **Derecha:** distribución porcentual con etiquetas de proporción. El sombreado naranja corresponde a la era pedagógica antigua (202320–202410) y el verde a la nueva (202420–202520).

Table 1: Composición por semestre, era pedagógica y resultado académico final.

Semestre	Era	Total	APROBÓ		REPROBÓ		RETIRADO		SIN NOTA
			<i>n</i>	%	<i>n</i>	%	<i>n</i>	%	
202320	Antigua	170	116	68,2	27	15,9	27	15,9	0
202410	Antigua	150	68	45,3	14	9,3	30	20,0	38
202420	Nueva	164	90	54,9	33	20,1	40	24,4	1
202510	Nueva	140	70	50,0	47	33,6	21	15,0	2
202520	Nueva	140	69	49,3	20	14,3	46	32,9	5
Total	—	764	413	54,1	141	18,5	164	21,5	46

- **Era Antigua** (202320 y 202410; $n = 320$ estudiantes activos): las evaluaciones continuas consisten en talleres individuales y proyectos por fases grupales.
- **Era Nueva** (202420, 202510 y 202520; $n = 444$ estudiantes activos): las evaluaciones continuas son actividades modulares (AMs) y quizzes individuales.

Dentro de la era nueva existe una distinción adicional: en 202420 las AMs se realizaron **en grupo**, mientras que a partir de 202510 pasaron a ser **individuales**. Este cambio produce diferencias estadísticamente significativas en la distribución de AM-3 (U -test, $p = 1,39 \times 10^{-9}$, $d_{\text{Cohen}} = 0,40$, $\text{AUC}_{\text{grupo}} = 0,369$ vs. $\text{AUC}_{\text{ind.}} = 0,246$), lo que justifica incluir la variable `modalidad_am` como control en los modelos entrenados con datos del formato nuevo.

1.2 Definición y Justificación de los Subconjuntos de Trabajo

El dataset bruto requiere dos depuraciones sucesivas antes de ser apto para el modelado de clasificación.

1.2.1 Exclusión de estudiantes retirados y sin calificación

Los 164 estudiantes con resultado **RETIRADO** y los 46 con **SIN NOTA** se excluyen por tres razones:

1. **Ausencia de etiqueta objetivo observable.** El SAT modela $P(\text{REPROBÓ} \mid \mathbf{x}_i)$, la probabilidad de que un estudiante *finalice* el semestre reprobando. Los estudiantes retirados abandonaron el curso antes de producirse el resultado; su etiqueta final es desconocida y no puede inferirse sin supuestos fuertes.
2. **Sesgo de retiro endógeno.** La decisión de retirarse está correlacionada con el desempeño anticipado: los estudiantes que perciben que van a reprobando se retiran en mayor proporción [2]. Incluirlos en la clase **REPROBÓ** introduciría sesgo de selección en las variables de engagement: un estudiante retirado en la semana 4 tiene engagement mínimo no por falta de habilidad sino por abandono temprano, contaminando el predictor más utilizado.
3. **Heterogeneidad semántica.** La predicción del retiro como fenómeno independiente requeriría modelos multi-clase y supuestos adicionales sobre su equivalencia con la reprobación, lo cual está fuera del alcance del presente trabajo.

El subconjunto resultante es `df_activos` ($N = 554$; APROBÓ: 413, REPROBÓ: 141).

1.2.2 Exclusión adicional de estudiantes sin actividad en plataforma

Del subconjunto `df_activos`, 52 estudiantes (9,4 %) presentan **engagement total nulo** en Bloque Neón durante todo el semestre (i.e., `engagement_hasta_p1` = 0). Estos casos se excluyen del subconjunto de modelado por las razones siguientes:

1. **Ambigüedad del cero.** Existen dos interpretaciones mutuamente excluyentes: (a) el estudiante genuinamente no utilizó la plataforma, o (b) ocurrió un error en el pipeline de integración de datos. Ambas hipótesis son plausibles: 39 de los 52 casos (75%) se concentran en el semestre 202320, el primero en incorporar Bloque Neón, cuando el sistema estaba aún en fase de implementación. No es posible distinguir entre causas con la información disponible.
2. **Riesgo de imputación espuria.** Imputar cero como valor real de engagement asumiría que “no usar la plataforma” es una señal homogénea entre semestres, cuando los patrones de no-uso varían considerablemente entre cohortes.
3. **Impacto estadístico marginal confirmado.** Se realizó un análisis de sensibilidad: los modelos entrenados sobre `df_activos` completo ($N = 554$) y sobre el subconjunto filtrado ($N = 502$) arrojan diferencias en F1 menores a $\Delta F_1 < 0,02$, confirmando que la exclusión no altera las conclusiones.

El subconjunto de modelado final es `df_activos_engagement` ($N = 502$; APROBÓ: 373, REPROBÓ: 129). La Tabla 2 resume los tres subconjuntos empleados en el análisis.

Table 2: Subconjuntos de trabajo. `df_activos_engagement` es el conjunto empleado para el entrenamiento y evaluación de todos los modelos del SAT.

Subconjunto	N	APROBÓ	REPROBÓ	Uso principal
<code>df_all</code>	764	413	141	Tasas globales, análisis de retiro
<code>df_activos</code>	554	413	141	Análisis de notas y distribuciones
<code>df_activos_engagement</code>	502	373	129	Entrenamiento y evaluación de m

1.3 Calidad y Estructura de los Datos

1.3.1 Nulos estructurales versus problemáticos

El dataset presenta un volumen considerable de valores faltantes, en su mayoría atribuibles al cambio de formato pedagógico. Se distinguen dos categorías.

Nulos estructurales (esperados). Son variables que solo existen en una era y, por tanto, están ausentes de forma legítima en la otra: `quiz_4/5/6` (77,8 % de nulos, solo en algunos semestres del formato nuevo), `taller_1/2/3` (59,4 %, exclusivo de la era antigua), `fase_1/2` (59,4 %, proyectos grupales de la era antigua), y `am_4/5/6` (56,7 %, AMs opcionales no presentes en todos los semestres). Estos nulos no representan problemas de calidad sino de diseño del instrumento de evaluación.

Nulos problemáticos (casos especiales). Son faltantes en variables que deberían estar presentes para todos los estudiantes activos:

- **Parcial 1 = 0 ($n = 1$):** un único estudiante registra nota cero. No es posible distinguir ausencia de nota real. Se retiene con variable indicadora `no_presento_p1`.
- **Parcial 3 = 0 ($n = 15$; 13 reprobaron):** concentrado en estudiantes encaminados a reprobado, consistente con ausentismo por desmotivación al final del semestre. Se retienen con su valor real.
- **Notas superiores a 5,0:** presentes por bonificaciones otorgadas por docentes. Son valores legítimos y se retienen sin transformación.


1.3.2 Variables de plataforma sin poder discriminativo

La plataforma Bloque Neón registra tanto métricas de *estudio de contenidos* como métricas de *actividades evaluativas en línea*. El análisis estadístico univariante sobre estas últimas —`actividades_n_realizadas`, `actividades_tiempo_total` y `actividades_visitas_total`— revela ausencia de poder discriminativo entre aprobados y reprobados (Tabla 3), lo que se ilustra también en la Figura 2.

Table 3: Variables de actividades evaluativas de la plataforma. $AUC \approx 0,5$ y $p > 0,05$ indican que no discriminan mejor que la clasificación aleatoria.

Variable	Med. APROBÓ	Med. REPROBÓ	AUC	p -valor (MW)
<code>actividades_n_realizadas</code>	1,00	1,00	0,473	0,830
<code>actividades_tiempo_total</code>	1,15	1,10	0,498	0,532
<code>actividades_visitas_total</code>	9,00	11,00	0,465	0,886

Nótese que, para `actividades_visitas_total`, la mediana de los reprobados (11) supera la de los aprobados (9), con $AUC = 0,465$ —peor que la clasificación aleatoria—, lo que sugiere que los estudiantes con mayor número de visitas a actividades no necesariamente obtienen mejores resultados. Las tres variables son excluidas del conjunto de predictores para evitar introducir ruido en los modelos.



Formato Antiguo

Formato Nuevo

Figure 2: Distribuciones de las tres variables de actividades evaluativas para aprobados (azul) y reprobados (rojo). Los valores de $p > 0,05$ y $AUC < 0,5$ confirman la ausencia de poder discriminativo, justificando su exclusión del conjunto de predictores.

1.4 Análisis Estadístico de las Notas Académicas

El análisis de notas se realiza sobre `df_activos` ($N = 554$) para preservar la distribución real sin los filtros de engagement.

1.4.1 Distribución de la nota final

La nota final (escala 0–5) presenta una distribución bimodal con dos concentraciones claramente separadas: una en torno a 2,6 (zona de reprobación) y otra en torno a 3,7 (zona de aprobación cómoda), como se observa en la Figura 3.




Figure 3: Distribución de la nota final. **Izquierda:** histogramas superpuestos con curva de densidad KDE por resultado académico. La línea discontinua vertical indica el umbral de aprobación (3,0). **Derecha:** diagramas de caja por semestre y resultado; el sombreado distingue las eras pedagógicas.

Las estadísticas descriptivas detalladas se presentan en la Tabla 4. La prueba de Mann-Whitney confirma la separación altamente significativa entre grupos ($U = 58\,233,0$, $p = 9,97 \times 10^{-71}$, $d_{\text{Cohen}} = 2,41$). Esta magnitud del efecto implica que la distribución de notas de los aprobados y la de los reprobados se solapan apenas en una pequeña región central (alrededor de $[2,8; 3,2]$), que es precisamente la zona donde los modelos de clasificación concentran su incertidumbre.

1.4.2 Poder predictivo de los parciales: análisis por era pedagógica

La Figura 4 compara la distribución de las tres calificaciones de parciales entre aprobados y reprobados, estratificada por era pedagógica.

La Tabla 5 sintetiza los AUC univariantes por variable y era. El hallazgo más relevante es la **reducción del poder predictivo de P1 en la era nueva** ($\Delta\text{AUC} = -0,087$). Esta caída puede atribuirse al mayor peso relativo de las actividades continuas (quizzes y AMs) en el nuevo currículo, que diluye la señal del primer examen. Contrariamente, el Parcial 2

Table 4: Estadísticas descriptivas de la nota final por resultado y era pedagógica. $\bar{x}$: media; $\tilde{x}$: mediana; s : desviación estándar.

Grupo	N	$\bar{x}$	$\tilde{x}$	s
APROBÓ (global)	413	3,724	3,620	0,527
REPROBÓ (global)	141	2,418	2,632	0,583
Era Antigua — APROBÓ	184	3,777	3,680	0,504
Era Antigua — REPROBÓ	41	2,446	2,720	0,671
Era Nueva — APROBÓ	229	3,682	3,530	0,541
Era Nueva — REPROBÓ	100	2,407	2,605	0,545




Figure 4: Distribuciones de Parcial 1, Parcial 2 y Parcial 3 por resultado académico, estratificadas por era pedagógica. Cada subgráfico incluye el p -valor de la prueba Mann-Whitney, el AUC univariante y el coeficiente de rango biserial r_b .

mantiene una capacidad predictiva alta y estable en ambas eras ($\Delta\text{AUC} = -0,025$), lo que refuerza el valor del segundo checkpoint (CP2) del SAT.

Table 5: AUC univariante de las variables académicas por era pedagógica. ΔAUC indica la variación entre eras. Diferencias $> 5\%$ se consideran sustanciales.

Variable	AUC Era Antigua	AUC Era Nueva	ΔAUC	Sustancial
Parcial 1	0,869	0,781	-0,087	Sí
Parcial 2	0,925	0,900	-0,025	No
Parcial 3	0,931	0,845	-0,086	Sí
Prom. AMs	0,737	0,731	-0,006	No

La Figura 5 ilustra visualmente esta comparación, tanto para las variables académicas como para los patrones de engagement entre eras.




Figure 5: **Izquierda:** AUC univariante de variables académicas por era pedagógica. La línea discontinua roja marca el umbral mínimo del SAT ($\text{AUC} = 0,75$). **Derecha:** medianas de engagement por era y resultado académico, normalizadas para comparación entre variables de diferente escala.

1.4.3 Poder predictivo temprano del Parcial 1: tabla de riesgo empírico

El primer checkpoint del SAT (CP1, semana 6) opera únicamente con la información disponible en ese momento, siendo el Parcial 1 el predictor individual más potente. La Figura 6 y la Tabla 6 cuantifican el riesgo empírico de reprobación por intervalo de nota de P1 sobre `df_activos` ($N = 554$).

Los resultados son contundentes en los extremos: estudiantes con $P1 < 1,5$ tienen una probabilidad empírica del 84,2 % de reprobación, mientras que con $P1 \geq 4,0$ esa probabilidad




Figure 6: **Izquierda:** diagrama de dispersión entre la nota del Parcial 1 y la nota final, coloreado por resultado académico. Las líneas discontinuas marcan el umbral de aprobación (3,0). La correlación de Spearman se muestra en el recuadro. **Derecha:** tasa de reprobación empírica por intervalo de P1. La línea discontinua horizontal indica la tasa global de reprobación (25,7 %).

Table 6: Tabla de riesgo empírico de reprobación por intervalo de nota en Parcial 1 (CP1, semana 6).

Intervalo P1	Nivel	N	P(APROBÓ)	P(REPROBÓ)	$\bar{x}$ nota final
[0,0; 1,5)	Crítico	19	15,8 %	84,2 %	2,16
[1,5; 2,5)	Alto	102	43,1 %	56,9 %	2,80
[2,5; 3,0)	Moderado	100	68,0 %	32,0 %	3,10
[3,0; 3,5)	Límite	128	85,9 %	14,1 %	3,44
[3,5; 4,0)	Seguro	95	83,2 %	16,8 %	3,62
[4,0; 5,0]	Sólido	110	99,1 %	0,9 %	4,18

cae al 0,9 %. Sin embargo, el intervalo $[2,5; 3,5)$, que concentra 228 estudiantes (41,2 % del total activo), presenta tasas de reprobación intermedias (14–32 %) donde la nota del parcial tiene menor poder de discriminación. Este es precisamente el segmento donde el engagement y otros predictores complementarios tienen mayor valor incremental.

1.4.4 Trayectorias académicas $P1 \rightarrow P2 \rightarrow P3$

Más allá del nivel absoluto de P1, la *trayectoria* de desempeño a lo largo de los tres parciales provee información adicional sobre el resultado final. Se identifican cinco patrones cualitativamente distintos (Figura 7 y Tabla 7).




Figure 7: Trayectorias de desempeño académico entre parciales. **Izquierda:** frecuencia de cada trayectoria por resultado académico. **Derecha:** evolución de la nota promedio en cada parcial por trayectoria, con el porcentaje de aprobación de cada grupo en la leyenda. La línea discontinua marca el umbral de 3,0.

Table 7: Patrones de trayectoria académica identificados en la secuencia $P1 \rightarrow P2 \rightarrow P3$. Los porcentajes se calculan dentro de cada grupo de trayectoria.

Trayectoria	Total	APROBÓ	REPROBÓ	% APR.
Declive sostenido ($P1 > P2 > P3$)	40	22	18	55,0 %
Estable ($P1 \approx P2 \approx P3$)	306	225	81	73,5 %
Mejora sostenida ($P1 < P2 < P3$)	22	20	2	90,9 %
Pico intermedio ($P1 < P2 > P3$)	129	99	30	76,7 %
Recuperación post-P1 ($P1 < P2$)	57	47	10	82,5 %

El grupo de **declive sostenido** concentra la mayor tasa de reprobación (45,0 %) y es identificable a partir de la comparación $P1 \rightarrow P2$ disponible en CP2. La **mejora**

sostenida es el patrón con mayor probabilidad de aprobación (90,9 %), lo que indica que la trayectoria ascendente es una señal de éxito más fiable que el nivel absoluto de P1.

Más relevante aún para el diseño del SAT: 115 de los 221 estudiantes con $P1 < 3,0$ terminaron aprobando (52,0 %), con nota media de Parcial 2 = 3,46 y nota final media = 3,38. Este fenómeno de *recuperación académica* demuestra que un clasificador basado únicamente en P1 tendría una tasa de falsas alarmas del 52 % entre los estudiantes de riesgo moderado, motivando explícitamente la revisión del estado de alerta en el segundo checkpoint (CP2, semana 11).

1.5 Análisis de la Actividad en Plataforma (Engagement)

El análisis de engagement se realiza sobre `df_activos_engagement` ($N = 502$): 373 aprobados y 129 reprobados. La Figura 8 muestra la composición de este subconjunto.




Figure 8: Composición del subconjunto de modelado (`df_activos_engagement`, $N = 502$). **Izquierda:** distribución de clases. El desbalance 74,3 % / 25,7 % motiva el uso de técnicas de balanceo (SMOTE, SMOTEENN). **Derecha:** descomposición por semestre, con el porcentaje de reprobados sobre cada barra.

1.5.1 Descripción de las métricas de engagement

Bloque Neón registra el comportamiento de estudio en dos dimensiones complementarias:

- **Amplitud de estudio (cobertura):** módulos únicos visitados (`parcial_X_modulos_unicos`), temas únicos consultados (`parcial_X_temas_unicos`) y visitas totales al contenido (`parcial_X_visitas`).
- **Profundidad de estudio (intensidad):** tiempo promedio por visita (`parcial_X_tiempo_por_v`) y visitas promedio por tema (`parcial_X_visitas_por_tema`).

Además, se dispone del tiempo acumulado hasta cada checkpoint (`engagement_hasta_p1`, `engagement_hasta_p2`) y del total del semestre (`total_tiempo_hrs`).

1.5.2 Diferencias estadísticas entre aprobados y reprobados: prueba de Mann-Whitney

La Figura 9 presenta las distribuciones de las principales variables de engagement disponibles en CP1 por semestre y resultado, y la Tabla 8 reporta los estadísticos completos de las pruebas Mann-Whitney.




Figure 9: Distribución de las cuatro principales variables de engagement en CP1 por semestre y resultado académico. El sombreado naranja indica la era antigua y el verde la nueva. En cada subgráfico se reportan el p -valor de Mann-Whitney, el AUC univariante y el coeficiente de rango biserial r_b .

Table 8: Prueba Mann-Whitney para variables de engagement disponibles en CP1. $\tilde{x}$: mediana; r_b : coeficiente de rango biserial [3]. Significancia: *** $p < 0,001$; * $p < 0,05$.

Variable	$\tilde{x}$ APR.	$\tilde{x}$ REP.	AUC	r_b	p -valor
Tiempo hasta P1 (h)	8,27	5,71	0,602	0,204	$2,8 \times 10^{-4}$ ***
Módulos únicos P1	7,00	6,00	0,601	0,203	$2,7 \times 10^{-4}$ ***
Visitas contenido P1	37,00	32,00	0,575	0,150	$1,1 \times 10^{-2}$ *
Temas únicos P1	12,00	11,00	0,567	0,134	$2,3 \times 10^{-2}$ *
Visitas por tema P1	3,20	2,83	0,565	0,130	$2,8 \times 10^{-2}$ *
Minutos por visita P1	12,26	11,07	0,562	0,125	$3,5 \times 10^{-2}$ *

Todas las variables de engagement en CP1 presentan diferencias estadísticamente significativas ($p < 0,05$), pero los tamaños del efecto son **pequeños** ($r_b \in [0,12; 0,20]$), muy

por debajo de los observados para las variables académicas (Tabla 9).

Table 9: Prueba Mann-Whitney para variables académicas. Todas presentan tamaños del efecto grandes ($d_{\text{Cohen}} \geq 0,91$) con significancia $p < 10^{-15}$.

Variable	$\tilde{x}$ APR.	$\tilde{x}$ REP.	AUC	r_b	d_{Cohen}	p -valor
Parcial 1	3,42	2,43	0,810	0,620	1,24	$1,8 \times 10^{-28}$
Parcial 2	3,80	2,33	0,861	0,722	1,56	$6,7 \times 10^{-38}$
Parcial 3	3,48	1,70	0,882	0,763	1,66	$4,7 \times 10^{-42}$
Prom. AMs	4,11	3,12	0,728	0,456	0,91	$2,9 \times 10^{-16}$
Prom. Quizzes	4,00	2,91	0,821	0,642	1,36	$1,0 \times 10^{-20}$

1.5.3 Poder discriminativo individual: ranking de AUC

La Figura 10 resume el poder discriminativo individual de cada variable disponible en CP1 mediante su AUC univariante, ordenado de mayor a menor.




Figure 10: AUC univariante de cada predictor candidato para CP1. Las variables académicas (azul) dominan ampliamente; las de engagement (verde) se ubican en la zona $[0,56; 0,60]$, superando la clasificación aleatoria pero por debajo del umbral mínimo del SAT (0,75, línea verde discontinua). Prom. Quizzes no está disponible en CP1 para todos los semestres.

La brecha entre el AUC de Parcial 1 (0,810) y el del mejor predictor de engagement (Tiempo hasta P1: 0,602) es de 20,8 puntos porcentuales. Esto confirma que el engagement

es un predictor *complementario*, no un sustituto de las calificaciones. Su valor radica en los casos marginales donde la nota de P1 tiene menor poder de discriminación (zona $[2,5; 3,5]$ de la tabla de riesgo).

1.5.4 Valor incremental del engagement y correlación parcial

Para cuantificar el aporte del engagement *más allá* de lo que ya captura Parcial 1, se calcula la correlación de Spearman entre el tiempo de engagement hasta P1 y la nota final, controlando por la nota de P1. El resultado es $\rho_{\text{parcial}} = 0,166$ ($p = 1,9 \times 10^{-4}$, $N = 502$), indicando que el engagement explica un 2-3% de varianza adicional en el resultado. Aunque modesto en términos absolutos, este aporte es estadísticamente robusto y operacionalmente relevante en la zona de incertidumbre del clasificador.

1.5.5 Patrones de acumulación de engagement entre checkpoints

La Figura 11 explora cómo se acumula el engagement entre los dos checkpoints del SAT.




Figure 11: **Izquierda:** correlación entre el tiempo de engagement hasta P1 y hasta P2 por resultado académico (ρ_{Spearman} reportado). La diagonal discontinua indica el punto de no-incremento entre checkpoints. **Derecha:** distribución del incremento de engagement en cada período por resultado (violines). Los p -valores corresponden a pruebas Mann-Whitney entre estados.

La correlación entre el engagement hasta P1 y hasta P2 es alta para ambos grupos (aprobados: $\rho \approx 0,86$; reprobados: similar), lo que indica **persistencia de los hábitos de estudio**: los estudiantes que estudian más en el primer período tienden a hacerlo también en el segundo. Los aprobados acumulan en el período P1 $\rightarrow$ P2 una mediana de 6,80 horas adicionales frente a 4,85 de los reprobados; esta diferencia se amplía hacia el

final del semestre (5,29 h vs. 3,28 h en el período P2 → fin). Este patrón sugiere que los estudiantes en riesgo no solo estudian menos, sino que además reducen progresivamente su dedicación conforme avanza el semestre.

1.6 Análisis de Correlaciones y Multicolinealidad

1.6.1 Correlaciones entre variables de engagement

La Figura 12 presenta la matriz de correlaciones de Spearman entre las variables de engagement y la dispersión entre tiempo hasta P1 y nota del Parcial 1.




Figure 12: **Izquierda:** matriz de correlaciones de Spearman entre variables de engagement (triángulo inferior). Las celdas en rojo oscuro indican correlaciones altas ($r > 0,80$). **Derecha:** dispersión entre tiempo de engagement hasta P1 y nota del Parcial 1 por resultado académico, con línea de regresión y correlación de Spearman.

Las correlaciones intra-período son altas: los pares más problemáticos son tiempo hasta P1 $\leftrightarrow$ tiempo hasta P2 ($r = 0,864$), temas P1 $\leftrightarrow$ módulos P1 ($r = 0,861$), tiempo P2 $\leftrightarrow$ tiempo total ($r = 0,852$) y temas total $\leftrightarrow$ módulos total ($r = 0,941$). Esta multicolinealidad no impide el modelado pero requiere regularización en los modelos lineales y justifica la selección de subconjuntos representativos de cada dimensión de engagement en lugar de incluir todas las variables simultáneamente.

1.6.2 Factor de inflación de varianza (VIF)

El análisis VIF sobre el conjunto de predictores candidatos revela que las variables académicas presentan los valores más altos (Parcial 1: VIF = 13,7; AM 2: VIF = 10,4; AM 1: VIF = 9,4), mientras que las de engagement son más moderadas (módulos únicos P1: VIF = 7,2; tiempo hasta P1: VIF = 4,0; tiempo por visita P1: VIF = 3,9). Ningún valor supera el umbral de 15 que produce inestabilidad severa, pero la magnitud de algunos VIF justifica el uso de regularización L1/L2 en los modelos de regresión logística (ver Sección ??).

1.7 Síntesis: Decisiones de Diseño del Dataset

La Tabla 10 sintetiza las decisiones de preprocesamiento tomadas a partir del análisis exploratorio.

El dataset de modelado resultante (`df_activos_engagement`, $N = 502$) presenta tres características estructurales que condicionan el diseño metodológico de la siguiente sección: (i) **desbalance de clases** (74,3 % vs. 25,7 %), que exige técnicas de remuestreo para evitar que los modelos sesguen la predicción hacia la clase mayoritaria; (ii) **estructura longitudinal multisemestral**, que invalida la validación cruzada aleatoria estándar y exige el esquema LOSO; y (iii) **heterogeneidad de era pedagógica**, que requiere variables de control y análisis estratificado. Estos tres aspectos se abordan en detalle en la sección de metodología.

References

- [1] J. López-Zambrano, J. A. Lara Torralbo, y C. Romero, “Early prediction of student learning performance through data mining: A systematic review,” *Psicothema*, vol. 33, no. 3, pp. 456–465, 2021.
- [2] V. Tinto, *Leaving College: Rethinking the Causes and Cures of Student Attrition*, 2.^a ed. Chicago, IL, USA: University of Chicago Press, 1993.

Table 10: Resumen de decisiones de diseño del dataset con justificación empírica e impacto cuantificado.

Decisión	Justificación	Impacto
Excluir RETIRADO y SIN NOTA	Etiqueta no observable; sesgo de retiro endógeno; heterogeneidad semántica	$N: 764 \rightarrow 554$
Excluir estudiantes sin engagement	Cero ambiguo (75 % en semestre de arranque); $\Delta F_1 < 0,02$ al excluirlos	$N: 554 \rightarrow 502$
Excluir variables de actividades evaluativas	$AUC < 0,50$; $p > 0,05$ (sin discriminación)	-3 predictores candidatos
Incluir <code>era_encoded</code>	$\Delta AUC(P1) = -0,087$; engagement mediano cae 60 % en era nueva	Control en todos los modelos
Incluir <code>modalidad_am</code>	AM-3 grupal vs. individual: $p = 1,4 \times 10^{-9}$, $d = 0,40$	Control en modelos con AMs
Incluir engagement a pesar de efecto pequeño	$\rho_{\text{parcial}} = 0,166$, $p < 0,001$; valor incremental en zona marginal de P1	+6 predictores en CP1
Aplicar balanceo SMOTE / SMOTEENN	74,3 % APROBÓ vs. 25,7 % REPROBÓ; Recall sin balanceo $\approx 0,55$	Solo en training fold; nunca en evaluación

- [3] D. S. Kerby, “The simple difference formula: An approach to teaching nonparametric correlation,” *Compr. Psychol.*, vol. 3, p. 11.IT.3.4.1, 2014.
- [4] H. He y E. A. Garcia, “Learning from imbalanced data,” *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, sep. 2009.