

Universidad de los Andes

Sistema de Alerta Temprana (SAT)

IIND-2104 Modelos Probabilísticos

Documento de Tesis

Marco teórico y exploración de datos

Autores:

Nicolás Torres Pulido

Isabella Delgadillo Calero

Asesor:

Juan Fernando Pérez Bernal

Abril de 2026

Índice general

Presentación del documento	1
1. Marco Teórico	2
1.1. Predicción del Rendimiento Académico y Sistemas de Alerta Temprana . .	2
1.2. Modelos de Clasificación Supervisada	2
1.3. Regresión Logística	3
1.4. Árbol de Decisión	3
1.5. Bosque Aleatorio (Random Forest)	4
1.6. XGBoost	4
1.7. Manejo de Datos Desbalanceados	4
1.8. SMOTE	5
1.9. SMOTEENN	5
1.10. Métricas de Evaluación	5
1.11. Validación: Leave-One-Semester-Out (LOSO)	6
1.12. Criterio de Selección de Modelos	7
2. Descripción y Exploración de Datos	8
2.1. Fuente y Composición del Conjunto de Datos	8
2.2. Dos eras pedagógicas	9
2.3. Exclusión de estudiantes retirados y sin calificación	10
2.4. Exclusión adicional de estudiantes sin actividad en plataforma	10
2.5. Nulos estructurales versus problemáticos	11
2.6. Variables de plataforma sin poder discriminativo	12
2.7. Distribución de la nota final	12
2.8. Poder predictivo de los parciales: análisis por era pedagógica	14
2.9. Poder predictivo temprano del Parcial 1: tabla de riesgo empírico	16
2.10. Trayectorias académicas $P1 \rightarrow P2 \rightarrow P3$	17
2.11. Descripción de las métricas de engagement	18

2.12. Diferencias estadísticas entre aprobados y reprobados: prueba de Mann-Whitney	18
2.13. Poder discriminativo individual: ranking de AUC	20
2.14. Valor incremental del engagement y correlación parcial	20
2.15. Patrones de acumulación de engagement entre checkpoints	21
2.16. Correlaciones entre variables de engagement	22
2.17. Síntesis: Decisiones de Diseño del Dataset	23
Referencias	24

Índice de figuras

1.1.	Esquema LOSO con cinco semestres (202320–202520).	7
2.1.	Composición del dataset por semestre y resultado académico. Izquierda: distribución absoluta. Derecha: distribución porcentual con etiquetas de proporción. El sombreado naranja corresponde a la era pedagógica antigua (202320–202410) y el verde a la nueva (202420–202520).	9
2.2.	Distribución de la nota final. Izquierda: histogramas superpuestos con curva de densidad KDE por resultado académico. La línea discontinua vertical indica el umbral de aprobación (3,0). Derecha: diagramas de caja por semestre y resultado; el sombreado distingue las eras pedagógicas.	13
2.3.	Distribuciones de Parcial 1, Parcial 2 y Parcial 3 por resultado académico, estratificadas por era pedagógica.	14
2.4.	Probabilidad empírica de reprobación según intervalos de Parcial 1, estratificada por era pedagógica. Izquierda: formato antiguo ($N = 225$). Derecha: formato nuevo ($N = 329$). En cada barra se muestra la composición porcentual de estudiantes que APROBÓ y REPROBÓ, junto con el tamaño muestral del intervalo.	15
2.5.	Izquierda: distribución de estudiantes que APROBÓ y REPROBÓ en cada intervalo de nota del Parcial 1, con el tamaño muestral de cada grupo y una clasificación cualitativa del nivel de riesgo (crítico, alto, moderado, límite, seguro, sólido). Derecha: nota final media por intervalo de P1, con barras de error de una desviación estándar. La línea discontinua horizontal marca el umbral de aprobación (3,0).	16
2.6.	Trayectorias de desempeño académico entre parciales. Izquierda: frecuencia de cada trayectoria por resultado académico. Derecha: evolución de la nota promedio en cada parcial por trayectoria, con el porcentaje de aprobación de cada grupo en la leyenda. La línea discontinua marca el umbral de 3,0.	17

2.7.	Distribución de las cuatro principales variables de engagement en CP1 por semestre y resultado académico. El sombreado naranja indica la era antigua y el verde la nueva. En cada subgráfico se reportan el p -valor de Mann-Whitney, el AUC univariante y el coeficiente de rango biserial r_b	19
2.8.	AUC univariante de cada predictor candidato para CP1. Las variables académicas (azul) dominan ampliamente; las de engagement (verde) se ubican en la zona $[0,56; 0,60]$, superando la clasificación aleatoria pero por debajo del umbral mínimo del SAT (0,75, línea verde discontinua). Prom. Quizzes no está disponible en CP1 para todos los semestres.	20
2.9.	Izquierda: correlación entre el tiempo de engagement hasta P1 y hasta P2 por resultado académico (ρ_{Spearman} reportado). La diagonal discontinua indica el punto de no-incremento entre checkpoints. Derecha: distribución del incremento de engagement en cada período por resultado (violines). Los p -valores corresponden a pruebas Mann-Whitney entre estados.	21
2.10.	Izquierda: matriz de correlaciones de Spearman entre variables de engagement (triángulo inferior). Las celdas en rojo oscuro indican correlaciones altas ($r > 0,80$). Derecha: dispersión entre tiempo de engagement hasta P1 y nota del Parcial 1 por resultado académico, con línea de regresión y correlación de Spearman.	22

Índice de cuadros

1.1. Matriz de confusión para clasificación binaria. VP: Verdaderos Positivos; VN: Verdaderos Negativos; FP: Falsos Positivos; FN: Falsos Negativos. . .	5
2.1. Composición por semestre, era pedagógica y resultado académico final. . .	9
2.2. Subconjuntos de trabajo. <code>df_activos_engagement</code> es el conjunto empleado para el entrenamiento y evaluación de todos los modelos del SAT.	11
2.3. Variables de actividades evaluativas de la plataforma. $AUC \approx 0,5$ y $p > 0,05$ indican que no discriminan mejor que la clasificación aleatoria.	12
2.4. Estadísticas descriptivas de la nota final por resultado y era pedagógica. $\bar{x}$: media; $\tilde{x}$: mediana; s : desviación estándar.	13
2.5. AUC univariante de las variables académicas por era pedagógica. ΔAUC indica la variación entre eras. Diferencias superiores al 5 % se consideran sustanciales.	15
2.6. Tabla de riesgo empírico de reprobación por intervalo de nota en Parcial 1 (CP1, semana 6).	16
2.7. Patrones de trayectoria académica identificados en la secuencia $P1 \rightarrow P2 \rightarrow P3$. Los porcentajes se calculan dentro de cada grupo de trayectoria.	18
2.8. Prueba Mann-Whitney para variables de engagement disponibles en CP1. $\tilde{x}$: mediana; r_b : coeficiente de rango biserial [11]. Significancia: *** $p < 0,001$; * $p < 0,05$	19
2.9. Prueba Mann-Whitney para variables académicas. Todas presentan tamaños del efecto grandes ($d_{\text{Cohen}} \geq 0,91$) con significancia $p < 10^{-15}$	19
2.10. Resumen de decisiones de diseño del dataset con justificación empírica e impacto cuantificado.	23

Presentación del documento

Este documento integra en una sola pieza académica el marco teórico y la exploración de datos del Sistema de Alerta Temprana (SAT) diseñado para el curso IIND-2104 *Modelos Probabilísticos*. La organización responde a una estructura de tesis: primero se presentan los fundamentos conceptuales y metodológicos que sostienen el problema de predicción, y luego se expone la caracterización empírica del conjunto de datos, con sus decisiones de depuración, análisis estadísticos y justificación del diseño del pipeline analítico.

Capítulo 1

Marco Teórico

Este capítulo expone los fundamentos conceptuales y metodológicos del Sistema de Alerta Temprana (SAT). Se estructura en cinco bloques: (i) predicción del rendimiento académico en educación superior; (ii) modelos de clasificación supervisada; (iii) manejo de datos desbalanceados; (iv) métricas de evaluación; y (v) esquema de validación temporal.

1.1. Predicción del Rendimiento Académico y Sistemas de Alerta Temprana

La predicción temprana del rendimiento estudiantil mediante minería de datos es un campo de investigación activo cuyo propósito es identificar estudiantes en riesgo con suficiente anticipación como para que las intervenciones docentes sean efectivas [1]. Una revisión sistemática de 82 trabajos publicados hasta 2021 constató que los algoritmos de clasificación —en particular Naïve Bayes, árboles de decisión y regresión logística— son los más frecuentes en este dominio, y que el momento de predicción más útil corresponde a las primeras semanas del semestre, cuando aún queda tiempo de intervención [1].

El SAT propuesto opera en dos *checkpoints*: la semana 6 (poscálculo del Parcial 1) y la semana 11 (poscálculo del Parcial 2), dejando ventanas de intervención de 11 y 6 semanas respectivamente. Este diseño responde directamente a la recomendación de equilibrar la cantidad de información disponible con la amplitud de la ventana de intervención [1].

1.2. Modelos de Clasificación Supervisada

Un modelo de clasificación supervisada aprende una función $f: \mathcal{X} \rightarrow \mathcal{Y}$ a partir de un conjunto de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, donde $\mathbf{x}_i \in \mathbb{R}^p$ es el vector de características del

estudiante i e $y_i \in \{\text{APROBÓ}, \text{REPROBÓ}\}$ es su clase objetivo [1]. A continuación se describen los cuatro algoritmos evaluados en este trabajo.

1.3. Regresión Logística

La regresión logística modela la probabilidad de la clase positiva mediante la función sigmoide aplicada a una combinación lineal de los predictores:

$$P(y = 1 \mid \mathbf{x}) = \frac{\exp(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}{1 + \exp(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x})}, \quad (1.1)$$

donde $\boldsymbol{\beta}$ se estima por máxima verosimilitud. Su interpretabilidad —los coeficientes representan cambios en el log-odds— la hace especialmente apropiada en contextos educativos donde la transparencia del modelo es relevante [1].

Para controlar el sobreajuste, se incorpora regularización. La **regularización L2 (Ridge)** penaliza $\lambda \|\boldsymbol{\beta}\|_2^2$ y encoge todos los coeficientes uniformemente. La **regularización L1 (Lasso)** penaliza $\lambda \|\boldsymbol{\beta}\|_1$ y produce soluciones *sparse*, llevando algunos coeficientes exactamente a cero y realizando así selección implícita de variables [3]. El hiperparámetro $C = 1/\lambda$ controla la intensidad de la penalización: valores pequeños de C implican mayor regularización, lo cual es especialmente importante con tamaños de muestra reducidos (270–505 estudiantes activos por checkpoint).

1.4. Árbol de Decisión

Un árbol de decisión particiona recursivamente el espacio de características mediante reglas binarias sobre atributos individuales [2]. En cada nodo, el algoritmo selecciona el atributo x_j y el umbral t que minimizan la impureza de las ramas resultantes. La métrica estándar en clasificación es la impureza de Gini:

$$G(S) = \sum_{k \in \mathcal{Y}} \hat{p}_k (1 - \hat{p}_k), \quad (1.2)$$

donde $\hat{p}_k$ es la proporción de instancias de clase k en el nodo S . Los hiperparámetros de poda (`max_depth`, `min_samples_leaf`) controlan la complejidad del árbol y el equilibrio sesgo-varianza [2].

1.5. Bosque Aleatorio (Random Forest)

El bosque aleatorio (*Random Forest*) es un método de *ensemble* que combina B árboles de decisión entrenados sobre muestras bootstrap del conjunto de entrenamiento [4]. Para construir cada árbol, en cada nodo se selecciona el mejor atributo entre un subconjunto aleatorio de $m \approx \sqrt{p}$ variables. La predicción final se obtiene por votación mayoritaria:

$$\hat{y} = \arg \max_k \sum_{b=1}^B \mathbf{1}[h_b(\mathbf{x}) = k]. \quad (1.3)$$

La doble aleatorización —bootstrap y selección de atributos— reduce la varianza sin incrementar apreciablemente el sesgo, produciendo modelos con buena capacidad de generalización [4]. Adicionalmente, el algoritmo proporciona medidas de importancia de variables basadas en el descenso promedio de impureza, facilitando la identificación de qué características del estudiante son más informativas.

1.6. XGBoost

XGBoost (*Extreme Gradient Boosting*) construye los árboles de manera secuencial: cada nuevo árbol f_t minimiza la función de pérdida residual de los árboles anteriores [5]:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n \ell\left(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)\right) + \Omega(f_t), \quad (1.4)$$

donde $\ell(\cdot)$ es la log-pérdida para clasificación binaria y $\Omega(f_t) = \gamma T + \frac{1}{2}\lambda\|\mathbf{w}\|^2$ penaliza la complejidad del árbol (T hojas, pesos $\mathbf{w}$) [5]. Entre sus ventajas prácticas se cuentan: procesamiento paralelo, manejo nativo de valores faltantes, y regularización L1/L2 incorporada.

1.7. Manejo de Datos Desbalanceados

En el conjunto de datos del SAT, los estudiantes que reprueban representan aproximadamente el 21 % frente a un 56 % que aprueba. Este desbalance de clases es intrínseco al fenómeno: en cualquier curso universitario, la clase mayoritaria es la de aprobados. Cuando los clasificadores se entrenan directamente sobre datos desbalanceados, maximizan la exactitud global prediciendo casi siempre la clase mayoritaria, lo que produce un recall bajo para la clase minoritaria de interés (**REPROBÓ**) [6]. Para mitigarlo, se aplican

dos estrategias de remuestreo sintético *exclusivamente* sobre el conjunto de entrenamiento dentro de cada fold de validación, evitando así fuga de información.

1.8. SMOTE

SMOTE (*Synthetic Minority Over-sampling Technique*) genera instancias sintéticas de la clase minoritaria mediante interpolación lineal en el espacio de características [7]. Para cada muestra $\mathbf{x}_i$ de la clase minoritaria, se selecciona aleatoriamente uno de sus k vecinos más cercanos $\mathbf{x}_{nn}$ y se crea una nueva instancia:

$$\mathbf{x}_{\text{new}} = \mathbf{x}_i + \delta \cdot (\mathbf{x}_{nn} - \mathbf{x}_i), \quad \delta \sim \mathcal{U}(0, 1). \quad (1.5)$$

Al operar en el espacio de características en lugar de duplicar instancias existentes, SMOTE genera fronteras de decisión más suaves y reduce el sobreajuste a puntos individuales [7].

1.9. SMOTEENN

SMOTEENN combina SMOTE con la técnica de limpieza *Edited Nearest Neighbours* (ENN) [8]. Tras generar instancias sintéticas, ENN elimina toda observación —de cualquier clase— cuya etiqueta difiera de la mayoritaria entre sus k vecinos más cercanos. Esta depuración reduce el ruido en las regiones fronterizas y generalmente produce mejores fronteras de separación que SMOTE por sí solo [8].

1.10. Métricas de Evaluación

La exactitud global (*accuracy*) no es apropiada bajo desbalance de clases, pues puede ser alta simplemente prediciendo siempre la clase mayoritaria [6]. Las métricas empleadas se derivan de la matriz de confusión (Tabla 1.1).

Cuadro 1.1: Matriz de confusión para clasificación binaria. VP: Verdaderos Positivos; VN: Verdaderos Negativos; FP: Falsos Positivos; FN: Falsos Negativos.

		Predicción	
		REPROBÓ	APROBÓ
Real	REPROBÓ	VP	FN
	APROBÓ	FP	VN

Recall (Sensibilidad). Mide la proporción de casos positivos correctamente detectados:

$$\text{Recall} = \frac{\text{VP}}{\text{VP} + \text{FN}}. \quad (1.6)$$

En el SAT, un falso negativo (estudiante en riesgo no detectado) tiene un costo mayor que un falso positivo (intervención innecesaria). Por esta razón, el Recall de la clase **REPROBÓ** es la métrica principal, con umbral objetivo $\geq 0,70$ [1].

Precisión.

$$\text{Precisión} = \frac{\text{VP}}{\text{VP} + \text{FP}}. \quad (1.7)$$

F1-score macro. Promedia el F1 de cada clase con peso igual, independientemente de su frecuencia [6]:

$$F_1^{\text{macro}} = \frac{1}{2} \sum_{k \in \mathcal{Y}} \frac{2 \cdot \text{Precisión}_k \cdot \text{Recall}_k}{\text{Precisión}_k + \text{Recall}_k}. \quad (1.8)$$

Umbral objetivo: $F_1^{\text{macro}} \geq 0,65$.

AUC-ROC. El área bajo la curva ROC cuantifica la capacidad discriminativa del modelo a lo largo de todos los umbrales posibles [9]:

$$\text{AUC} = \int_0^1 \text{TPR}(u) \, d\text{FPR}(u). \quad (1.9)$$

Un valor $\text{AUC} = 0,5$ corresponde a clasificación aleatoria y $\text{AUC} = 1,0$ a clasificación perfecta. Umbral objetivo: $\text{AUC} \geq 0,75$.

1.11. Validación: Leave-One-Semester-Out (LOSO)

La validación cruzada estándar *k-fold* asume que los datos son intercambiables, supuesto que no se cumple en datos longitudinales de cursos académicos: los sílabos, docentes y condiciones pedagógicas varían entre semestres. Para respetar esta estructura temporal, se adopta la estrategia **Leave-One-Semester-Out (LOSO)**: en cada fold, un semestre completo se reserva como conjunto de prueba y los cuatro restantes se usan para entrenamiento (Figura 1.1).

Las métricas reportadas son promedios aritméticos de los cinco folds (LOSO media), que estiman el desempeño esperado ante un semestre futuro no observado. Este esquema es

Fold 1: Train {202410, 202420, 202510, 202520} $\rightarrow$ Test {202320}
Fold 2: Train {202320, 202420, 202510, 202520} $\rightarrow$ Test {202410}
$\vdots$
Fold 5: Train {202320, 202410, 202420, 202510} $\rightarrow$ Test {202520}

Figura 1.1: Esquema LOSO con cinco semestres (202320–202520).

considerablemente más conservador que la partición aleatoria y es el estándar recomendado en sistemas de alerta temprana educativa [1].

El remuestreo (SMOTE o SMOTEENN) y la búsqueda de hiperparámetros mediante `GridSearchCV` con validación cruzada estratificada interna de 5 pliegues se aplican *exclusivamente* sobre los datos de entrenamiento de cada fold, garantizando que las instancias sintéticas no contaminen la evaluación [7].

1.12. Criterio de Selección de Modelos

El criterio de selección entre modelos candidatos se aplica por separado en cada uno de los dos *checkpoints* evaluados (CP1 y CP2):

1. **Filtro de discriminación:** conservar únicamente los modelos con $AUC_{\text{LOSO}} \geq 0,75$.
2. **Selección final por objetivo:** entre los modelos que superan ese umbral, escoger tres modelos por checkpoint: uno que maximice el $\text{Recall}_{\text{LOSO}}(\text{REPROBÓ})$, otro que maximice la $\text{Precisión}_{\text{LOSO}}(\text{REPROBÓ})$ y otro que maximice $F_{1,\text{LOSO}}^{\text{macro}}$.

De esta manera, para cada checkpoint se obtiene un conjunto de tres modelos candidatos con desempeños complementarios: uno orientado a detectar la mayor cantidad posible de estudiantes en riesgo, otro a reducir falsos positivos y otro a balancear de forma global precisión y exhaustividad. Este esquema permite comparar alternativas alineadas con distintos objetivos de intervención, manteniendo como requisito común una capacidad discriminativa mínima aceptable [1, 9].

Capítulo 2

Descripción y Exploración de Datos

Este capítulo caracteriza el conjunto de datos empleado en el SAT, documenta las decisiones de preprocesamiento adoptadas y presenta los hallazgos del análisis exploratorio que fundamentan el diseño del sistema de modelado. La presentación se organiza en seis bloques: (i) fuente y composición del dataset; (ii) definición y justificación de los subconjuntos de trabajo; (iii) calidad y estructura de los datos; (iv) análisis estadístico de las notas académicas; (v) análisis de la actividad en plataforma; y (vi) análisis de correlaciones y síntesis de decisiones de diseño.

2.1. Fuente y Composición del Conjunto de Datos

Los datos provienen del curso IIND-2104 *Modelos Probabilísticos* de la Universidad de los Andes, dictado entre los semestres 202320 y 202520 —cinco cohortes consecutivas cubiertas entre 2023 y 2025. La información se integra a partir de dos fuentes complementarias:

- **Sistema de gestión académica institucional:** calificaciones oficiales de los tres parciales y de las evaluaciones continuas (actividades modulares, quizzes, talleres y proyectos, según el formato de cada semestre).
- **Plataforma Bloque Neón:** sistema de gestión del aprendizaje (LMS) que registra, por sesión y por módulo de contenido, el tiempo de estudio, los temas consultados, los módulos visitados y la frecuencia de acceso de cada estudiante.

El dataset crudo consolidado cuenta con **764 registros y 77 variables**, con cuatro posibles resultados académicos finales: **APROBÓ** (413 estudiantes, 54,1 %), **REPROBÓ** (141, 18,5 %), **RETIRADO** (164, 21,5 %) y **SIN NOTA** (46, 6,0 %).

La Figura 2.1 ilustra cómo se distribuyen estos resultados por semestre en términos absolutos y porcentuales, y la Tabla 2.1 detalla las frecuencias exactas.




Figura 2.1: Composición del dataset por semestre y resultado académico. **Izquierda:** distribución absoluta. **Derecha:** distribución porcentual con etiquetas de proporción. El sombreado naranja corresponde a la era pedagógica antigua (202320–202410) y el verde a la nueva (202420–202520).

Cuadro 2.1: Composición por semestre, era pedagógica y resultado académico final.

Semestre	Era	Total	APROBÓ		REPROBÓ		RETIRADO		SIN NOTA
			<i>n</i>	%	<i>n</i>	%	<i>n</i>	%	
202320	Antigua	170	116	68,2	27	15,9	27	15,9	0
202410	Antigua	150	68	45,3	14	9,3	30	20,0	38
202420	Nueva	164	90	54,9	33	20,1	40	24,4	1
202510	Nueva	140	70	50,0	47	33,6	21	15,0	2
202520	Nueva	140	69	49,3	20	14,3	46	32,9	5
Total	—	764	413	54,1	141	18,5	164	21,5	46

2.2. Dos eras pedagógicas

Un rasgo estructural del dataset es la coexistencia de dos **formatos de evaluación continua**:

- **Era Antigua** (202320 y 202410; $n = 320$ estudiantes activos): las evaluaciones continuas consisten en talleres individuales y proyectos por fases grupales.

- **Era Nueva** (202420, 202510 y 202520; $n = 444$ estudiantes activos): las evaluaciones continuas son actividades modulares (AMs) y quizzes individuales.

2.3. Exclusión de estudiantes retirados y sin calificación

Los 164 estudiantes con resultado RETIRADO y los 46 con SIN NOTA se excluyen por tres razones:

1. **Ausencia de etiqueta objetivo observable.** El SAT modela $P(\text{REPROBÓ} \mid \mathbf{x}_i)$, la probabilidad de que un estudiante *finalice* el semestre reprobando. Los estudiantes retirados abandonaron el curso antes de producirse el resultado; su etiqueta final es desconocida y no puede inferirse sin supuestos fuertes.
2. **Sesgo de retiro endógeno.** La decisión de retirarse está correlacionada con el desempeño anticipado: los estudiantes que perciben que van a reprobando se retiran en mayor proporción [10]. Incluirlos en la clase REPROBÓ introduciría sesgo de selección en las variables de engagement, ya que la plataforma borra los datos de visitas y tiempo una vez el estudiante retira.
3. **Heterogeneidad semántica.** La predicción del retiro como fenómeno independiente requeriría modelos multi-clase y supuestos adicionales sobre su equivalencia con la reprobación, lo cual está fuera del alcance del presente trabajo.

El subconjunto resultante es `df_activos` ($N = 554$; APROBÓ: 413, REPROBÓ: 141).

2.4. Exclusión adicional de estudiantes sin actividad en plataforma

Del subconjunto `df_activos`, 52 estudiantes (9,4 %) presentan **engagement total nulo** en Bloque Neón durante todo el semestre (i.e., `engagement_hasta_p1 = 0`). Estos casos se excluyen del subconjunto de modelado por las razones siguientes:

1. **Ambigüedad del cero.** Existen dos interpretaciones mutuamente excluyentes: (a) el estudiante genuinamente no utilizó la plataforma, o (b) ocurrió un error en el pipeline de integración de datos. No es posible distinguir entre causas con la información disponible.

2. **Riesgo de imputación espuria.** Imputar cero como valor real de engagement asumiría que “no usar la plataforma” es una señal homogénea entre semestres, cuando los patrones de no-uso varían considerablemente entre cohortes.

El subconjunto de modelado final es `df_activos_engagement` ($N = 502$; APROBÓ: 373, REPROBÓ: 129). La Tabla 2.2 resume los tres subconjuntos empleados en el análisis.

Cuadro 2.2: Subconjuntos de trabajo. `df_activos_engagement` es el conjunto empleado para el entrenamiento y evaluación de todos los modelos del SAT.

Subconjunto	N	APROBÓ	REPROBÓ	Uso principal
<code>df_all</code>	764	413	141	Tasas globales, análisis de retiro
<code>df_activos</code>	554	413	141	Análisis de notas y distribuciones
<code>df_activos_engagement</code>	502	373	129	Entrenamiento y evaluación de m

2.5. Nulos estructurales versus problemáticos

El dataset presenta un volumen considerable de valores faltantes, en su mayoría atribuibles al cambio de formato pedagógico. Se distinguen dos categorías.

Nulos estructurales (esperados). Son variables que solo existen en una era y, por tanto, están ausentes de forma legítima en la otra: `quiz_4/5/6`, `taller_1/2/3`, `fase_1/2`, y `am_4/5/6`. Estos nulos no representan problemas de calidad sino de diseño del instrumento de evaluación.

Nulos problemáticos (casos especiales). Son faltantes en variables que deberían estar presentes para todos los estudiantes activos:

- **Parcial 1 = 0 ($n = 1$):** un único estudiante registra nota cero. No es posible distinguir ausencia de nota real. Se retiene con variable indicadora `no_presento_p1`.
- **Notas superiores a 5,0:** presentes por bonificaciones otorgadas por docentes. Son valores legítimos y se retienen sin transformación.

2.6. Variables de plataforma sin poder discriminativo

La plataforma Bloque Neón registra tanto métricas de *estudio de contenidos* como métricas de *actividades evaluativas en línea*. El análisis estadístico univariante sobre estas últimas —`actividades_n_realizadas`, `actividades_tiempo_total` y `actividades_visitas_total`— revela ausencia de poder discriminativo entre aprobados y reprobados (Tabla 2.3), lo que se ilustra también en la Figura ??.

Cuadro 2.3: Variables de actividades evaluativas de la plataforma. $AUC \approx 0,5$ y $p > 0,05$ indican que no discriminan mejor que la clasificación aleatoria.

Variable	Med. APROBÓ	Med. REPROBÓ	AUC	p -valor (MW)
<code>actividades_n_realizadas</code>	1,00	1,00	0,473	0,830
<code>actividades_tiempo_total</code>	1,15	1,10	0,498	0,532
<code>actividades_visitas_total</code>	9,00	11,00	0,465	0,886

Nótese que, para `actividades_visitas_total`, la mediana de los reprobados (11) supera la de los aprobados (9), con $AUC = 0,465$ —peor que la clasificación aleatoria—, lo que sugiere que los estudiantes con mayor número de visitas a actividades no necesariamente obtienen mejores resultados. Las tres variables son excluidas del conjunto de predictores para evitar introducir ruido en los modelos.

2.7. Distribución de la nota final

El análisis de notas se realiza sobre `df_activos` ($N = 554$) para preservar la distribución real sin los filtros de engagement. La nota final (escala 0–5) presenta una distribución bimodal con dos concentraciones claramente separadas: una en torno a 2,6 (zona de reprobación) y otra en torno a 3,7 (zona de aprobación cómoda), como se observa en la Figura 2.2.

Las estadísticas descriptivas detalladas se presentan en la Tabla 2.4. La prueba de Mann-Whitney confirma la separación altamente significativa entre grupos ($U = 58\,233,0$, $p = 9,97 \times 10^{-71}$, $d_{\text{Cohen}} = 2,41$). Esta magnitud del efecto implica que la distribución de notas de los aprobados y la de los reprobados se solapan apenas en una pequeña región central (alrededor de $[2,8; 3,2]$), que es precisamente la zona donde los modelos de clasificación concentran su incertidumbre.




Figura 2.2: Distribución de la nota final. **Izquierda:** histogramas superpuestos con curva de densidad KDE por resultado académico. La línea discontinua vertical indica el umbral de aprobación (3,0). **Derecha:** diagramas de caja por semestre y resultado; el sombreado distingue las eras pedagógicas.

Cuadro 2.4: Estadísticas descriptivas de la nota final por resultado y era pedagógica. $\bar{x}$: media; $\tilde{x}$: mediana; s : desviación estándar.

Grupo	N	$\bar{x}$	$\tilde{x}$	s
APROBÓ (global)	413	3,724	3,620	0,527
REPROBÓ (global)	141	2,418	2,632	0,583
Era Antigua — APROBÓ	184	3,777	3,680	0,504
Era Antigua — REPROBÓ	41	2,446	2,720	0,671
Era Nueva — APROBÓ	229	3,682	3,530	0,541
Era Nueva — REPROBÓ	100	2,407	2,605	0,545

2.8. Poder predictivo de los parciales: análisis por era pedagógica

La Figura 2.3 compara la distribución de las tres calificaciones de parciales entre aprobados y reprobados, estratificada por era pedagógica.




Figura 2.3: Distribuciones de Parcial 1, Parcial 2 y Parcial 3 por resultado académico, estratificadas por era pedagógica.

La Tabla 2.5 sintetiza los AUC univariantes por variable y era. El hallazgo más relevante es la **reducción del poder predictivo de P1 en la era nueva** ($\Delta\text{AUC} = -0,087$). Esta caída puede atribuirse al mayor peso relativo de las actividades continuas (quizzes y AMs) en el nuevo currículo, que diluye la señal del primer examen. Contrariamente, el Parcial 2 mantiene una capacidad predictiva alta y estable en ambas eras ($\Delta\text{AUC} = -0,025$), lo que refuerza el valor del segundo checkpoint (CP2) del SAT.

La Figura 2.4 complementa la Tabla 2.5 mostrando la relación entre los intervalos de Parcial 1 y la probabilidad empírica de reprobación en cada era pedagógica. En ambas eras aparece un gradiente monótonico claro: a mayor nota de P1, menor proporción de estudiantes que terminan reprobando. No obstante, la era nueva exhibe una transición más suave en los intervalos intermedios, lo que es consistente con la reducción del poder discriminativo de P1 observada en la Tabla 2.5.

Cuadro 2.5: AUC univariante de las variables académicas por era pedagógica. ΔAUC indica la variación entre eras. Diferencias superiores al 5 % se consideran sustanciales.

Variable	AUC Era Antigua	AUC Era Nueva	ΔAUC	Sustancial
Parcial 1	0,869	0,781	-0,087	Sí
Parcial 2	0,925	0,900	-0,025	No
Parcial 3	0,931	0,845	-0,086	Sí
Prom. AMs	0,737	0,731	-0,006	No




Figura 2.4: Probabilidad empírica de reprobación según intervalos de Parcial 1, estratificada por era pedagógica. **Izquierda:** formato antiguo ($N = 225$). **Derecha:** formato nuevo ($N = 329$). En cada barra se muestra la composición porcentual de estudiantes que APROBÓ y REPROBÓ, junto con el tamaño muestral del intervalo.

2.9. Poder predictivo temprano del Parcial 1: tabla de riesgo empírico

El primer checkpoint del SAT (CP1, semana 6) opera únicamente con la información disponible en ese momento, siendo el Parcial 1 el predictor individual más potente. La Figura 2.5 y la Tabla 2.6 resumen ese patrón sobre `df_activos` ($N = 554$): la figura muestra, para cada intervalo de P1, tanto la proporción de estudiantes que aprueban o reprobaban como la nota final media asociada a ese tramo. De este modo, no solo se observa la probabilidad de reprobación, sino también cómo cambia el desempeño final esperado a medida que aumenta la nota del primer parcial.




Figura 2.5: **Izquierda:** distribución de estudiantes que APROBÓ y REPROBÓ en cada intervalo de nota del Parcial 1, con el tamaño muestral de cada grupo y una clasificación cualitativa del nivel de riesgo (crítico, alto, moderado, límite, seguro, sólido). **Derecha:** nota final media por intervalo de P1, con barras de error de una desviación estándar. La línea discontinua horizontal marca el umbral de aprobación (3,0).

Cuadro 2.6: Tabla de riesgo empírico de reprobación por intervalo de nota en Parcial 1 (CP1, semana 6).

Intervalo P1	Nivel	N	P(APROBÓ)	P(REPROBÓ)	$\bar{x}$ nota final
[0,0; 1,5)	Crítico	19	15,8 %	84,2 %	2,16
[1,5; 2,5)	Alto	102	43,1 %	56,9 %	2,80
[2,5; 3,0)	Moderado	100	68,0 %	32,0 %	3,10
[3,0; 3,5)	Límite	128	85,9 %	14,1 %	3,44
[3,5; 4,0)	Seguro	95	83,2 %	16,8 %	3,62
[4,0; 5,0]	Sólido	110	99,1 %	0,9 %	4,18

Los resultados son contundentes en los extremos: estudiantes con $P1 < 1,5$ tienen una probabilidad empírica del 84,2 % de reprobación, mientras que con $P1 \geq 4,0$ esa probabilidad cae al 0,9 %. Sin embargo, el intervalo $[2,5; 3,5)$, que concentra 228 estudiantes (41,2 % del total activo), presenta tasas de reprobación intermedias (14–32 %) donde la nota del parcial tiene menor poder de discriminación. Este es precisamente el segmento donde el engagement y otros predictores complementarios tienen mayor valor incremental.

2.10. Trayectorias académicas $P1 \rightarrow P2 \rightarrow P3$

Más allá del nivel absoluto de $P1$, la *trayectoria* de desempeño a lo largo de los tres parciales provee información adicional sobre el resultado final. Se identifican cinco patrones cualitativamente distintos (Figura 2.6 y Tabla 2.7).




Figura 2.6: Trayectorias de desempeño académico entre parciales. **Izquierda:** frecuencia de cada trayectoria por resultado académico. **Derecha:** evolución de la nota promedio en cada parcial por trayectoria, con el porcentaje de aprobación de cada grupo en la leyenda. La línea discontinua marca el umbral de 3,0.

El grupo de **declive sostenido** concentra la mayor tasa de reprobación (45,0 %) y es identificable a partir de la comparación $P1 \rightarrow P2$ disponible en CP2. La **mejora sostenida** es el patrón con mayor probabilidad de aprobación (90,9 %), lo que indica que la trayectoria ascendente es una señal de éxito más fiable que el nivel absoluto de $P1$.

Más relevante aún para el diseño del SAT: 115 de los 221 estudiantes con $P1 < 3,0$ terminaron aprobando (52,0 %), con nota media de Parcial 2 = 3,46 y nota final media = 3,38. Este fenómeno de *recuperación académica* demuestra que un clasificador basado únicamente en $P1$ tendría una tasa de falsas alarmas del 52 % entre los estudiantes de

Cuadro 2.7: Patrones de trayectoria académica identificados en la secuencia $P1 \rightarrow P2 \rightarrow P3$. Los porcentajes se calculan dentro de cada grupo de trayectoria.

Trayectoria	Total	APROBÓ	REPROBÓ	% APR.
Declive sostenido ($P1 > P2 > P3$)	40	22	18	55,0 %
Estable ($P1 \approx P2 \approx P3$)	306	225	81	73,5 %
Mejora sostenida ($P1 < P2 < P3$)	22	20	2	90,9 %
Pico intermedio ($P1 < P2 > P3$)	129	99	30	76,7 %
Recuperación post-P1 ($P1 < P2$)	57	47	10	82,5 %

riesgo moderado, motivando explícitamente la revisión del estado de alerta en el segundo checkpoint (CP2, semana 11).

2.11. Descripción de las métricas de engagement

La plataforma Bloque Neón registra el comportamiento de estudio a través de tiempo y visitas, por lo que se plantean dos dimensiones complementarias:

- **Amplitud de estudio (cobertura):** módulos únicos visitados (`parcial_X_modulos_unicos`), temas únicos consultados (`parcial_X_temas_unicos`) y visitas totales al contenido (`parcial_X_visitas`).
- **Profundidad de estudio (intensidad):** tiempo promedio por visita (`parcial_X_tiempo_por_vi`) y visitas promedio por tema (`parcial_X_visitas_por_tema`).

Además, se dispone del tiempo acumulado hasta cada checkpoint (`engagement_hasta_p1`, `engagement_hasta_p2`) y del total del semestre (`total_tiempo_hrs`).

2.12. Diferencias estadísticas entre aprobados y reprobados: prueba de Mann-Whitney

La Figura 2.7 presenta las distribuciones de las principales variables de engagement disponibles en CP1 por semestre y resultado, y la Tabla 2.8 reporta los estadísticos completos de las pruebas Mann-Whitney.

Todas las variables de engagement en CP1 presentan diferencias estadísticamente significativas ($p < 0,05$), pero los tamaños del efecto son **pequeños** ($r_b \in [0,12; 0,20]$), muy por debajo de los observados para las variables académicas (Tabla 2.9).

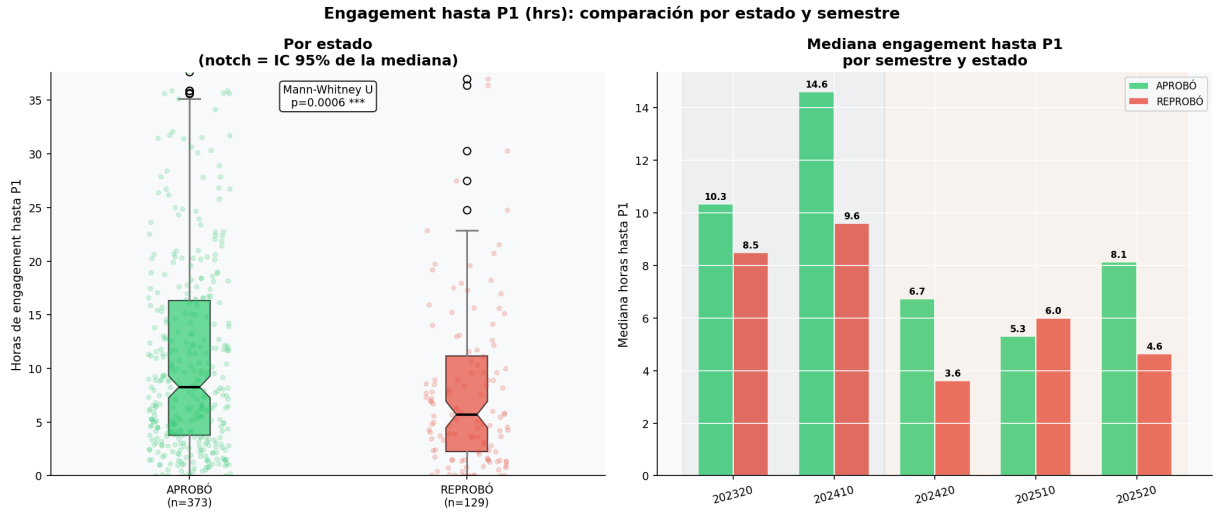


Figura 2.7: Distribución de las cuatro principales variables de engagement en CP1 por semestre y resultado académico. El sombreado naranja indica la era antigua y el verde la nueva. En cada subgráfico se reportan el p -valor de Mann-Whitney, el AUC univariante y el coeficiente de rango biserial r_b .

Cuadro 2.8: Prueba Mann-Whitney para variables de engagement disponibles en CP1. $\tilde{x}$: mediana; r_b : coeficiente de rango biserial [11]. Significancia: *** $p < 0,001$; * $p < 0,05$.

Variable	$\tilde{x}$ APR.	$\tilde{x}$ REP.	AUC	r_b	p -valor
Tiempo hasta P1 (h)	8,27	5,71	0,602	0,204	$2,8 \times 10^{-4}$ ***
Módulos únicos P1	7,00	6,00	0,601	0,203	$2,7 \times 10^{-4}$ ***
Visitas contenido P1	37,00	32,00	0,575	0,150	$1,1 \times 10^{-2}$ *
Temas únicos P1	12,00	11,00	0,567	0,134	$2,3 \times 10^{-2}$ *
Visitas por tema P1	3,20	2,83	0,565	0,130	$2,8 \times 10^{-2}$ *
Minutos por visita P1	12,26	11,07	0,562	0,125	$3,5 \times 10^{-2}$ *

Cuadro 2.9: Prueba Mann-Whitney para variables académicas. Todas presentan tamaños del efecto grandes ($d_{\text{Cohen}} \geq 0,91$) con significancia $p < 10^{-15}$.

Variable	$\tilde{x}$ APR.	$\tilde{x}$ REP.	AUC	r_b	d_{Cohen}	p -valor
Parcial 1	3,42	2,43	0,810	0,620	1,24	$1,8 \times 10^{-28}$
Parcial 2	3,80	2,33	0,861	0,722	1,56	$6,7 \times 10^{-38}$
Parcial 3	3,48	1,70	0,882	0,763	1,66	$4,7 \times 10^{-42}$
Prom. AMs	4,11	3,12	0,728	0,456	0,91	$2,9 \times 10^{-16}$
Prom. Quizzes	4,00	2,91	0,821	0,642	1,36	$1,0 \times 10^{-20}$

2.13. Poder discriminativo individual: ranking de AUC

La Figura 2.8 resume el poder discriminativo individual de cada variable disponible en CP1 mediante su AUC univariante, ordenado de mayor a menor.




Figura 2.8: AUC univariante de cada predictor candidato para CP1. Las variables académicas (azul) dominan ampliamente; las de engagement (verde) se ubican en la zona [0,56; 0,60], superando la clasificación aleatoria pero por debajo del umbral mínimo del SAT (0,75, línea verde discontinua). Prom. Quizzes no está disponible en CP1 para todos los semestres.

La brecha entre el AUC de Parcial 1 (0,810) y el del mejor predictor de engagement (Tiempo hasta P1: 0,602) es de 20,8 puntos porcentuales. Esto confirma que el engagement es un predictor *complementario*, no un sustituto de las calificaciones. Su valor radica en los casos marginales donde la nota de P1 tiene menor poder de discriminación (zona [2,5; 3,5] de la tabla de riesgo).

2.14. Valor incremental del engagement y correlación parcial

Para cuantificar el aporte del engagement *más allá* de lo que ya captura Parcial 1, se calcula la correlación de Spearman entre el tiempo de engagement hasta P1 y la nota final, controlando por la nota de P1. El resultado es $\rho_{\text{parcial}} = 0,166$ ($p = 1,9 \times 10^{-4}$,

$N = 502$), indicando que el engagement explica un 2–3 % de varianza adicional en el resultado. Aunque modesto en términos absolutos, este aporte es estadísticamente robusto y operacionalmente relevante en la zona de incertidumbre del clasificador.

2.15. Patrones de acumulación de engagement entre checkpoints

La Figura 2.9 explora cómo se acumula el engagement entre los dos checkpoints del SAT.




Figura 2.9: **Izquierda:** correlación entre el tiempo de engagement hasta P1 y hasta P2 por resultado académico (ρ_{Spearman} reportado). La diagonal discontinua indica el punto de no-incremento entre checkpoints. **Derecha:** distribución del incremento de engagement en cada período por resultado (violines). Los p -valores corresponden a pruebas Mann-Whitney entre estados.

La correlación entre el engagement hasta P1 y hasta P2 es alta para ambos grupos (aprobados: $\rho \approx 0,86$; reprobados: similar), lo que indica **persistencia de los hábitos de estudio**: los estudiantes que estudian más en el primer período tienden a hacerlo también en el segundo. Los aprobados acumulan en el período P1 $\rightarrow$ P2 una mediana de 6,80 horas adicionales frente a 4,85 de los reprobados; esta diferencia se amplía hacia el final del semestre (5,29 h vs. 3,28 h en el período P2 $\rightarrow$ fin). Este patrón sugiere que los estudiantes en riesgo no solo estudian menos, sino que además reducen progresivamente su dedicación conforme avanza el semestre.

2.16. Correlaciones entre variables de engagement

La Figura 2.10 presenta la matriz de correlaciones de Spearman entre las variables de engagement y la dispersión entre tiempo hasta P1 y nota del Parcial 1.




Figura 2.10: **Izquierda:** matriz de correlaciones de Spearman entre variables de engagement (triángulo inferior). Las celdas en rojo oscuro indican correlaciones altas ($r > 0,80$). **Derecha:** dispersión entre tiempo de engagement hasta P1 y nota del Parcial 1 por resultado académico, con línea de regresión y correlación de Spearman.

Las correlaciones intra-período son altas: los pares más problemáticos son tiempo hasta P1 $\leftrightarrow$ tiempo hasta P2 ($r = 0,864$), temas P1 $\leftrightarrow$ módulos P1 ($r = 0,861$), tiempo P2 $\leftrightarrow$ tiempo total ($r = 0,852$) y temas total $\leftrightarrow$ módulos total ($r = 0,941$). Esta multicolinealidad no impide el modelado pero requiere regularización en los modelos lineales y justifica la selección de subconjuntos representativos de cada dimensión de engagement en lugar de

incluir todas las variables simultáneamente.

2.17. Síntesis: Decisiones de Diseño del Dataset

La Tabla 2.10 sintetiza las decisiones de preprocesamiento tomadas a partir del análisis exploratorio.

Cuadro 2.10: Resumen de decisiones de diseño del dataset con justificación empírica e impacto cuantificado.

Decisión	Justificación	Impacto
Excluir RETIRADO y SIN NOTA	Etiqueta no observable; sesgo de retiro endógeno; heterogeneidad semántica	$N: 764 \rightarrow 554$
Excluir estudiantes sin engagement	Cero ambiguo (75 % en semestre de arranque); $\Delta F_1 < 0,02$ al excluirlos	$N: 554 \rightarrow 502$
Excluir variables de actividades evaluativas	$AUC < 0,50$; $p > 0,05$ (sin discriminación)	−3 predictores candidatos
Incluir <code>era_encoded</code>	$\Delta AUC(P1) = -0,087$; engagement mediano cae 60 % en era nueva	Control en todos los modelos
Incluir <code>modalidad_am</code>	AM-3 grupal vs. individual: $p = 1,4 \times 10^{-9}$, $d = 0,40$	Control en modelos con AMs
Incluir engagement a pesar de efecto pequeño	$\rho_{\text{parcial}} = 0,166$, $p < 0,001$; valor incremental en zona marginal de P1	+6 predictores en CP1
Aplicar balanceo SMOTE / SMO-TEENN	74,3 % APROBÓ vs. 25,7 % REPROBÓ; Recall sin balanceo $\approx 0,55$	Solo en training fold; nunca en evaluación

El dataset de modelado resultante (`df_activos_engagement`, $N = 502$) presenta tres características estructurales que condicionan el diseño metodológico de la siguiente sección: (i) **desbalance de clases** (74,3 % vs. 25,7 %), que exige técnicas de remuestreo para evitar que los modelos sesguen la predicción hacia la clase mayoritaria; (ii) **estructura longitudinal multisemestral**, que invalida la validación cruzada aleatoria estándar y exige el esquema LOSO; y (iii) **heterogeneidad de era pedagógica**, que requiere variables de control y análisis estratificado. Estos tres aspectos se abordan en detalle en la sección de metodología.

Bibliografía

- [1] J. López-Zambrano, J. A. Lara Torralbo, y C. Romero, “Early prediction of student learning performance through data mining: A systematic review,” *Psicothema*, vol. 33, no. 3, pp. 456–465, 2021. PDF libre: <https://www.psicothema.com/pdf/4692.pdf>
- [2] L. Breiman, J. H. Friedman, R. A. Olshen, y C. J. Stone, *Classification and Regression Trees*. Belmont, CA, USA: Wadsworth, 1984.
- [3] T. Hastie, R. Tibshirani, y J. Friedman, *The Elements of Statistical Learning*, 2.^a ed. New York, NY, USA: Springer, 2009. PDF libre (autor): <https://hastie.su.domains/ElemStatLearn/>
- [4] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001. PDF libre: <https://www.stat.berkeley.edu/~breiman/randomforest2001.pdf>
- [5] T. Chen y C. Guestrin, “XGBoost: A scalable tree boosting system,” en *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016, pp. 785–794. PDF libre (ACM OA): <https://dl.acm.org/doi/10.1145/2939672.2939785>
Preprint: <https://arxiv.org/abs/1603.02754>
- [6] H. He y E. A. Garcia, “Learning from imbalanced data,” *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, sep. 2009. Preprint libre: https://cs.utah.edu/~piyush/teaching/he_imbalanced.pdf
- [7] N. V. Chawla, K. W. Bowyer, L. O. Hall, y W. P. Kegelmeyer, “SMOTE: Synthetic minority over-sampling technique,” *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002. PDF libre (JAIR OA): <https://www.jair.org/index.php/jair/article/view/10302>
- [8] G. E. A. P. A. Batista, R. C. Prati, y M. C. Monard, “A study of the behavior of several methods for balancing machine learning training data,” *ACM SIGKDD Explor. Newslett.*, vol. 6, no. 1, pp. 20–29, 2004. PDF libre (ACM DL): <https://dl.acm.org/doi/10.1145/1007730.1007735>

- [9] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognit. Lett.*, vol. 27, no. 8, pp. 861–874, 2006. PDF libre: <https://people.inf.elte.hu/kiss/13dwhdm/roc.pdf>
- [10] V. Tinto, *Leaving College: Rethinking the Causes and Cures of Student Attrition*, 2.^a ed. Chicago, IL, USA: University of Chicago Press, 1993.
- [11] D. S. Kerby, “The simple difference formula: An approach to teaching nonparametric correlation,” *Compr. Psychol.*, vol. 3, p. 11.IT.3.4.1, 2014.